

GSIA - Previsão de risco de flares solares com Machine Learning


Integrantes: Vinicius Issa Gois (RM553814); Vinicius Caetano (RM552904); Gustavo Manganeli Felex (RM554242); Gustavo Bonani (RM553493); Wesley Leopoldino (RM553496)

Resumo técnico. A investigação avaliou se atributos de regiões ativas do Sol conseguem sinalizar risco de flares moderados ou severos (classes M ou X) nas próximas 24 horas. O evento é raro: 5.3% das 1389 observações tiveram flare M/X. Por isso, a solução priorizou recall e interpretação de risco, não apenas acurácia.

O modelo Naive Bayes categórico atingiu recall de 0.61, precisão de 0.20 e F2-score de 0.43 no conjunto de teste, usando limiar 0.24. Em uma aplicação de monitoramento espacial, esse ajuste é coerente porque deixar de alertar um evento relevante tende a ser mais grave do que acionar investigação adicional.

Flares relevantes são raros e criam um problema desbalanceado


A maior parte das regiões ativas não gerou flares M ou X. Esse desbalanceamento torna a acurácia isolada pouco informativa: um modelo que sempre prevê ausência de evento já pareceria correto na maioria dos casos, mas seria inútil para priorização de risco.



A classe Zurich concentra diferenças úteis de risco

A classe Zurich, que resume características morfológicas da região ativa, mostra diferenças claras na taxa observada de eventos M/X. Essas diferenças não provam causalidade, mas ajudam a construir uma fila de priorização para observação posterior.

Taxa de flares relevantes por classe Zurich



Modelo e avaliação favorecem detecção de eventos

Foi treinado um Naive Bayes categórico com suavização de Laplace, adequado para variáveis discretas e fácil de explicar. O alvo binário foi definido como 1 quando a região produziu ao menos um flare M ou X nas 24 horas seguintes. O limiar foi escolhido por F2-score, que dá mais peso ao recall.


Matriz de confusão no teste

Classe positiva: ocorrência de flare M ou X nas próximas 24h



Categorias com maior lift indicam sinais observacionais promissores

O lift compara a taxa de evento dentro de uma categoria com a taxa média do dataset. Valores acima de 1 indicam categorias nas quais flares M/X apareceram proporcionalmente mais. Como algumas categorias têm amostra pequena, o resultado deve ser lido como hipótese analítica, não como regra operacional definitiva.



Escopo, dados e definições

Dataset escolhido: UCI Machine Learning Repository - Solar Flare Dataset. Cada linha representa uma região ativa do Sol, descrita por dez atributos categóricos/ordinais, e três contagens-alvo: flares C, M e X produzidos nas 24 horas seguintes. Foram usadas as duas partições públicas, totalizando 1389 observações.

Limitações e robustez

O dataset é histórico, pequeno para padrões atuais e tem poucos eventos severos. A divisão treino/teste foi estratificada, mas as métricas podem variar com outra amostra. O modelo também assume independência condicional entre atributos, uma simplificação forte. Ainda assim, a análise é útil pedagogicamente porque expõe desbalanceamento, trade-off entre falso positivo e falso negativo e interpretação de variáveis.

Próximos passos recomendados

Para evoluir o trabalho, o grupo poderia comparar Naive Bayes com árvore de decisão, regressão logística ou Random Forest, incluir validação cruzada e calibrar probabilidades. Em uma aplicação real, também seria necessário atualizar os dados com fontes solares modernas e definir o custo operacional de cada tipo de erro.